

一、信息论基础.

1.1 自信息: 衡量事件的不确定性与信息量.

设发生 x 事件概率为 $p(x)$.

$$I(x) = -\log_2 p(x) \text{ (单位: 比特)}$$

性质: $p(x) \rightarrow 1, I(x) \rightarrow 0$ 确定信息无信息量.

$p(x) \rightarrow 0, I(x) \rightarrow \infty$ 小概率事件信息量大.

若 x, y 独立, $I(x, y) = I(x) + I(y)$.

1.2 信息熵: 衡量随机变量的平均不确定性.

设 X 为离散随机变量, 取值集合 X , 概率分布 $p(x)$.

$$H(X) = E[I(x)] = -\sum_{x \in X} p(x) \log_2 p(x).$$

最大值 $H(X) \leq \log_2 |X|$, 当均匀分布时成立.

$$\begin{aligned} \text{证: } \max \quad & -\sum_i p(x_i) \log_2 p(x_i) & \min \quad & \sum_i p(x_i) \log_2 p(x_i) \\ \text{s.t. } \quad & \sum_i p(x_i) = 1, p_i \geq 0 \quad \forall i & \Leftrightarrow & \text{s.t. } \sum_i p(x_i) = 1. \end{aligned}$$

$$\text{令 } a_i = p(x_i), \quad \sum_i a_i = 1.$$

$\because f(x) = -x \log_2 x$ 为凹函数, $-\sum x_i \log_2 x_i$ 仍为凹

$\because \sum a_i = 1, a_i \geq 0$,
等式约束 非负约束

$$\text{令 } L(a, \lambda) = -\sum a_i \log_2 a_i - \lambda (\sum a_i - 1)$$

$$\frac{\partial L}{\partial a_i} = -\log_2 a_i - \frac{1}{\ln 2} - \lambda = 0.$$

$$\log_2 a_i = -(\frac{1}{\ln 2} + \lambda).$$

$$\therefore a_1 = a_2 = \dots = a_n$$

$$\therefore a_i = \frac{1}{n}, \forall i$$

$\therefore H(x)$ 凹, 可行域凸且驻点唯一,

因此唯一全局最大值于此取得. $H(x)_{\max} = -n \times \frac{1}{n} \log_2 \frac{1}{n} = \log_2 n$.

凹函数在凸集上的最小值一定出现在可行域的极点上.

对于 $\sum p_i = 1, p_i \geq 0$, 极点为某个 $p_i = 1$, 其余全为 0. 此时 $H_{\min} = 0$.

1.2 条件熵: 已知 Y 时 X 的不确定性:

$$H(X|Y) = \sum_{y \in Y} p(y) H(X|Y=y) = - \sum_{x \in X} \sum_{y \in Y} p(x,y) \log_2 p(x|y).$$

性质: $H(X|Y) \leq H(X)$

链式法则: $H(X,Y) = H(X) + H(Y|X)$.

1.4 信息增益: $\text{Gain}(D,A) = H(D) - H(D|A)$

特征 A 对分类的贡献.

计算: 设特征 A 有 V 个取值: $\{a_1, \dots, a_V\}$, 则:

$$H(D|A) = \sum_{v=1}^V \frac{|D^v|}{|D|} H(D^v)$$

D^v 是 D 中特征 A 取值为 a_v 的子集.

例: 10 个西瓜

好瓜 4 个 特征: 形状. 圆瓜 4 (好瓜 3 坏瓜 1)
坏瓜 6 个 扁瓜 6 (好瓜 1 坏瓜 5).

$$H(\text{瓜}) = -0.4 \log_2 0.4 - 0.6 \log_2 0.6 \approx 0.97,$$

$$H(\text{瓜}|\text{圆}) = H(\text{好瓜}|\text{圆}) + H(\text{坏瓜}|\text{圆}) = -\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \approx 0.81,$$

$$H(\text{瓜}|\text{扁}) = -\frac{1}{6}\log_2\frac{1}{6} - \frac{5}{6}\log_2\frac{5}{6} \approx 0.650.$$

$$H(\text{瓜}|\text{形状}) = 0.4 \times 0.811 + 0.6 \times 0.650 \approx 0.714.$$

$\uparrow$ 4圆 $\uparrow$ 6扁.

$$\text{Gain}(\text{瓜}, \text{形状}) = H(\text{瓜}) - H(\text{瓜}|\text{形状}) \approx 0.971 - 0.714 = 0.257.$$

消除0.257的不确定性.
↓

二. ID3决策树(基于信息增益)

输入: 训练集D, 特征A, 阈值ε.

1. 若D中所有样本属于同一类 C_k .
将T标记为叶节点, 类别= C_k .
返回T

2. 若A= $\emptyset$,
将T标记为叶节点, 类别=D中样本最多的类.
返回T

3. 否则:

a. 计算每个特征的信息增益

b. 选择信息增益最大的特征 A_g

c. 如果 $\text{Gain}(D, A_g) < \epsilon$:

将T标记为叶节点, 类别=D中最多的类.
返回T

d. 否则:

对 A_g 每个取值 a_i

生成分支: $D_i = D$ 中 $A_g = a_i$ 的集合


如果 $D_i = \emptyset$:

将该分支标记为叶, 类别=D中样本最多的类

否则:

递归调用. $T_i = \text{Tree}(D_i, A - A_g)$ 为分支.

返回T.



1. 算当前数据集的熵
2. 对每个特征, 算Gain.
3. 选增益最大的特征当节点, 将数据分成几堆.
4. 对每一堆递归1~3步
5. 直到某一堆里全是好/坏瓜, 就停止, 成为叶子节点.

三. C4.5 决策树.

3.1. Gain 的缺陷: 偏好种类多的特征

3.2. 信息增益率: $\text{Gain-ratio}(D, A) = \frac{\text{Gain}(D, A)}{\text{IV}(A)}$

$$\text{IV}(A) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|} \quad (\text{熵值})$$

3.3. 选择策略: ① 先选 Gain 高于平均值的.

② 再选其中 Gain-ratio 最大的

$$A^* = \arg \max_{A \in A^*} \text{Gain-ratio}(D, A)$$

$$A' = \{A \in A \mid \text{Gain}(D, A) \geq \overline{\text{Gain}}\}$$

四. CART 决策树. 二叉树. 先选某一特征最有区度的

4.1. 基尼指数. $\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2$ p_k : 第 k 类样本比例

物理意义: 从 D 中随机抽两样本, 类别不同的概率

$$4.2. \text{Gini-index}(D, A) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

$$\Delta \text{Gini}(D, A) = \text{Gini}(D) - \text{Gini-index}(D, A)$$


CART 选择使 ΔGini 最大的特征.

五. 剪枝. (预防过拟合)

- 5.1 预剪枝:
- ① 节点样本数小于阈值
 - ② 样本纯度高于阈值.
 - ③ 信息增益(率)小于阈值.
 - ④ 树深度达阈值.

可能欠拟合

5.2. 后剪枝 对于 CART $C_\alpha(T) = C(T) + \alpha |T|$



1. 从空树 T_0 开始.

2. 对每个内部节点 t :

$$\text{剪枝前损失: } C_\alpha(T_t) = C(T_t) + \alpha |T_t|$$

$$\text{剪枝后损失: } C_\alpha(t) = C(t) + \alpha$$

若 $C_\alpha(t) \leq C_\alpha(T_t)$, 则剪枝

3. 选最优 α : 交叉验证.

六. 朴素贝叶斯

6. 给定特征 $x = (x_1, x_2, \dots, x_n)$ 判断属于哪一类 y .

要算 $P(y|x)$ 哪个类概率大就是哪个.

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)}.$$

$$P(y|x) \propto P(x|y)P(y).$$

假设: 给定特征在类别给定条件下相互独立.

$$P(x|y) = P(x_1|y)P(x_2|y)\dots P(x_n|y).$$

$$\text{最佳: } y^* = \arg \max_y [P(y) \prod_{i=1}^n P(x_i|y)]$$

$P(y)$ 先验 $P(x_i=a|y)$ 条件

拉普拉斯平滑. (避免概率为0)