

分类模型.

一、Logistic 回归 (二分类).

1.1 从线性回归到分类问题.

① 输入 $(-\infty, +\infty)$, 分类需要概率 $[0, 1]$

② 对异常值敏感

③ 需要引入连接函数 (link function).

1.2. Logistic (Sigmoid) 函数.

$$\sigma(z) = \frac{1}{1+e^{-z}} = \frac{e^z}{1+e^z}.$$

性质: ①. $\sigma(z) \in (0, 1)$.

② $\sigma(0) = 0.5$

③ $\sigma(-z) = 1 - \sigma(z)$.

④. $\sigma'(z) = \sigma(z)\sigma(-z) = \sigma(z)[1 - \sigma(z)]$.

1.3 Logistic 回归模型.

$$P(y=1 | x; w) = h_w(x) = \sigma(w^T x) = \frac{1}{1+e^{-w^T x}}$$

$$P(y=0 | x; w) = 1 - h_w(x) = \frac{e^{-w^T x}}{1+e^{-w^T x}}.$$

$$\text{几率 (比值)} = \frac{P(y=1|x)}{P(y=0|x)} = e^{w^T x}$$

$$\text{对数几率 (log-odds)}: \log \frac{P(y=1|x)}{P(y=0|x)} = w^T x$$

二、损失函数:

2.1. 交叉熵损失 (Cross-Entropy Loss).

设 $y_i \in \{0, 1\}$, 且 $y_i \sim B(\varphi_i)$. $\varphi_i = P(y_i=1) = h_w(x_i)$.

似然函数: $L(w) = \prod_{i=1}^n p(y_i|x_i; w) = \prod_{i=1}^n h_w(x_i)^{y_i} [1 - h_w(x_i)]^{1-y_i}$.

$$J(w) = -\log L(w) = -\sum_{i=1}^n [y_i \log h_w(x_i) + (1-y_i) \log (1-h_w(x_i))]$$

2.2. 广义最大似然估计.

指数族分布: $P(y|\eta) = h(y) \exp(\eta^T T(y) - A(\eta))$.

对二项分布: $\eta = \log \frac{\varphi}{1-\varphi}$, $T(y) = y$, $A(\eta) = \log(1+e^\eta)$

三、梯度下降.

$$3.1. J(w) = -\sum_{i=1}^n [y_i \log \sigma(w^T x_i) + (1-y_i) \log [1 - \sigma(w^T x_i)]]$$

先求: $\frac{\partial}{\partial w} \log \sigma(w^T x_i)$.

$$\frac{\partial}{\partial z} \sigma(z) = \sigma(z) \sigma(-z).$$

$$\frac{\partial}{\partial w} \log \sigma(w^T x_i) = \frac{1}{\sigma(w^T x_i)} \sigma(w^T x_i) \sigma(-w^T x_i) \cdot x_i$$

$$= \sigma(-w^T x_i) \cdot x_i = (1 - \sigma(w^T x_i)) x_i$$

$$\cdot \text{同理. } \frac{\partial}{\partial w} \log [1 - \sigma(w^T x_i)] = -\sigma(w^T x_i) x_i$$

$$\frac{\partial J}{\partial w} = -\sum_{i=1}^n [y_i [1 - \sigma(w^T x_i)] x_i - (1-y_i) \sigma(w^T x_i) x_i]$$

$$= \sum_{i=1}^n [\sigma(w^T x_i) - y_i] x_i.$$

矩阵形式: $\frac{\partial J}{\partial w} = X^T [\sigma(Xw) - y]$ $\sigma(Xw) = \begin{bmatrix} \sigma(w^T x_1) \\ \vdots \\ \sigma(w^T x_n) \end{bmatrix}$

3.2 正则化 logistic 回归.

$$J(w) = -\sum_{i=1}^n [y_i \log h_w(x_i) + (1-y_i) \log(1-h_w(x_i))] + \frac{\lambda}{2} \|w\|^2$$

$e = \sigma(Xw) - y$ $X^T = [x_1, x_2, \dots, x_n]$

$$\frac{\partial J}{\partial w} = X^T [\sigma(Xw) - y] + \lambda w$$

3.3. L1 正则化的 Laplace 先验

Laplace 分布: $p(w_j | \beta) = \frac{1}{2\beta} \exp(-\frac{|w_j|}{\beta})$

先验: $\log p(w | D) \propto \log p(D | w) + \log p(w) = \log p(D | w) - \frac{1}{\beta} \sum_{j=1}^d |w_j|$

最大后验估计: $w_{map} = \arg \max_w [-\log p(D | w) + \lambda \|w\|_1]$

$$\lambda = \frac{1}{\beta}$$

特点: ① 稀疏解 (存在 $w_j = 0$)
② 特征自动选择
③ 解不唯一.

四、多分类扩展.

4.1 二分类扩展至多分类.

1. 一对多 (One-vs-Rest, OvR) 训练 K 个二分类器.
2. 一对一 (One-vs-One, OvO) 训练 $\frac{K(K-1)}{2}$ 个分类器.

3. Softmax 函数 (直接分 K 类)

$$p(y=k | x; w) = \frac{e^{w_k^T x}}{\sum_{j=1}^K e^{w_j^T x}} \quad W = [w_1, w_2, \dots, w_K]$$

交叉熵损失 (使用 one-hot 编码)

$$J(W) = - \sum_{i=1}^n \sum_{k=1}^K y_{ik} \log p(y_i=k/x_i; W)$$

五、分类评价指标

5.1 混淆矩阵:

	预测 P	预测 N
实际 P	TP	FN
实际 N	FP	TN

5.2 重要指标:

指标	公式	解释
准确率	$\frac{TP+TN}{TP+FP+TN+FN}$	分类正确率
精确率	$\frac{TP}{TP+FP}$	预测 P 中实际 P 比例
召回率	$\frac{TP}{TP+FN}$	实际 P 中预测 P 比例
假正率	$\frac{FP}{FP+TN}$	实际 N 中预测 P 比例
F1 分数	$\frac{2}{\frac{1}{precision} + \frac{1}{recall}}$	

5.3 ROC 曲线与 AUC

以假正率为横轴, 真正率为纵轴.

随机分类器: 对角线

完美分类器 (0, 1)

绘制步骤: 1. 按预测概率从高到低排序 (也就是阈值).

2. 依次降低阈值, 计算 TPR 与 FPR

3. 连接所有点形成曲线.

AUC 物理意义: 随机选取一正一负, 分类器将正样本排至负样本前的概率.

常问:

1. 交叉熵函数为凸函数.

$$L = -y \log \sigma(w^T x) - (1-y) \log (1 - \sigma(w^T x))$$

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

$$\frac{\partial L}{\partial z} = \sigma(z) - y \quad \frac{\partial^2 L}{\partial z^2} = \sigma'(z) = \sigma(z)(1 - \sigma(z)) > 0.$$

对单样本, L 关于 z 为凸, $z = w^T x$ 是关于 w 的仿射变换.

多样本损失函数求和仍凸.

2. 为什么要用 Sigmoid 函数?

① $(-\infty, +\infty) \rightarrow [0, 1]$ 可解释为概率.

② 广义线性模型

二项分布属指数族, $\log P_p = w^T x$ 反解得 sigmoid

③ $\frac{\partial L}{\partial \theta} = (\sigma(z) - y)x$ 无饱和区梯度消失 (与 MSE 相比).

④ 损失函数为凸, 保证全局最优.

Sigmoid 是二项的自然连接分布, 输出为概率, 损失凸, 梯度简洁.

3. L_1 与 L_2 正则化几何解释.

框架: $J = J_{data} + \lambda \Omega(w)$

$\Leftrightarrow \min J_{data}$

s.t. $\Omega(w) \leq t$

L_2 正则 (岭回归), $\Omega(w) = \|w\|_2^2 = \sum w_i^2$

超球约束, 处处可导, 权重趋于小但非稀疏.

使用全部特征

L_1 正则 (Lasso), $\Omega(w) = \|w\|_1 = \sum |w_i|$

超菱形约束, 顶点在坐标轴上, 天然特征选择、稀疏解

使用少数特征

关于ROC的几个问题:

4. 如果 logistic 回归对所有样本 $\rightarrow 0.7$. ROC 曲线形状: $(0,0)$ 与 $(1,1)$.
完全没有区分能力.


5. 正负样本比例 $1:1 \rightarrow 1:4$. ROC 不变. (前提分布, 也就是“比例”一到).

$TPR = \frac{TP}{P}$ $FPR = \frac{FP}{N}$

这两个指标只依赖于排序, 不依赖于样本的绝对比例.

准确率会变, AUC 不变, Precision-Recall 会剧烈变化

AUC: 抓坏人能力 > 冤枉好人能力.



PR 曲线 精确-召回曲线

Precision - Recall


$\frac{TP}{TP+FP}$

抓的准确率

$TPR: \frac{TP}{TP+FN}$

抓坏人的能力

抓不到最不准



极度类别敏感, 当 $N \uparrow$, $FP \uparrow$, Precision $\downarrow$