

一、距离度量

1.1 闵可夫斯基距离族

$$d_p(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^p \right)^{\frac{1}{p}}$$

① $p=1$ 曼哈顿距离

$$d_1 = \sum_{i=1}^d \|x_i - y_i\|$$

② $p=2$ 欧氏距离:

$$d_2 = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$$

③ $p \rightarrow \infty$ 切比雪夫距离: $d_\infty = \max_i \|x_i - y_i\|$

③ 证明: 求 $\lim_{p \rightarrow \infty} \left(\sum_{i=1}^d a_i^p \right)^{\frac{1}{p}}$

设 $\max_i a_i = a_j$, 则

$$\left(\sum_{i=1}^d a_i^p \right)^{\frac{1}{p}} = a_j \left(1 + \left(\frac{a_1}{a_j} \right)^p + \dots + \left(\frac{a_d}{a_j} \right)^p \right)^{\frac{1}{p}}$$

$$a_j \leq \left(\sum_{i=1}^d a_i^p \right)^{\frac{1}{p}} \leq d^{\frac{1}{p}} a_j$$

由夹逼定理: $\lim_{p \rightarrow \infty} \left(\sum_{i=1}^d a_i^p \right)^{\frac{1}{p}} = a_j$

余弦距离 $d_{\cos}(x, y) = 1 - \frac{x^T y}{\|x\| \|y\|} = 1 - \cos \theta$

范围: $[0, 2]$. 对模长不敏感, 只关注方向.

常用于文本、推荐系统

(去中心化的余弦相似度)

皮尔逊相关系数距离: $d_{\text{corr}}(x, y) = 1 - \frac{(x - \bar{x})(y - \bar{y})}{\|x - \bar{x}\| \|y - \bar{y}\|}$

马氏距离: $d_M(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$ Σ : 协方差矩阵

$d_M(Ax, Ay) = d_M(x, y)$ 标准化、去相关、按分布密度加权.

$$P_M(\pi) = \sqrt{\pi^T \Sigma^{-1} \pi} \quad \Sigma = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})(x_i - \bar{x})^T$$

汉明距离: $d_H(\pi, y) = \sum_{i=1}^d \mathbb{I}(\pi_i \neq y_i)$

杰卡德距离: $J(A, B) = 1 - \frac{|A \cap B|}{|A \cup B|}$

二. K -means 距离.

2.1 给定 $D = \{x_i\}_{i=1}^n$, $x_i \in \mathbb{R}^d$, 划分为 K 个簇.

目标: 最小化 $J = \sum_{i=1}^n \sum_{k=1}^K r_{ik} \|x_i - \mu_k\|^2$

μ_k 为簇的中心, $r_{ik} \in \{0, 1\}$ 表示 x_i 是否属于簇 k .

步骤:

① 初始化: 随机选 K 个中心 $\mu_1, \mu_2, \dots, \mu_K$.

② 重复直至收敛 a. 分配步: 对样本 i , 分配到最近中心.

$$r_{ik} = 1 \text{ if } k = \underset{j}{\operatorname{argmin}} \|x_i - \mu_j\|$$

else 0

b. 更新步: 重新计算簇中心:

$$\mu_k = \frac{\sum_i r_{ik} x_i}{\sum_i r_{ik}} \leftarrow \text{平均位置.}$$

③ 输出: 簇分配与中心.

2.3 收敛性证明.

分配: 固定 μ_k , 选择最优 r_{ik} , J 不增.

更新: $\frac{\partial J}{\partial \mu_k} = -2 \sum_{i=1}^n r_{ik} (x_i - \mu_k) = 0$

最优解即 $\mu_k = \frac{\sum_i r_{ik} x_i}{\sum_i r_{ik}}$

J 有下界且单调不增, 算法收敛.

2.4 局限性.

①需指定 k : 肘部法选择 (k 个. SSE先快速下降, 拐点为肘部)

②对初始中心敏感: K-means++

↑
第一个点: 数据点中的随机点.

之后的中心: 计算每个点到已选最近中心的距离 $D(x)$.

以 $p \propto D(x)$ 的方式, 选下一个中心点.
离中心越远的越容易选中.

此处 $D(x) = \min_i (到 C_1, 到 C_2, \dots 到 C_{i-1})$

对剩余每个点都计算一次.

三、K-中心点 (K-medoids).

3.1.

	K-means	K-medoids
中心	均值点	实际样本点
度量	平方欧氏	任意距离
异常	敏感	稳健.
成本	低	高.

3.2. K-medoids 步骤 (CPAM).

①初始化: 随机选 k 个 medoids.

②重复: a. 分配: 每个点到最近 medoid.

b. 交换: 对每个 medoid m 与非 medoid o

计算交换 (m, o) 的总成本变化 Δ

如果 $\Delta < 0$, 执行交换.

③直至 $\Delta \geq 0$ 对所有可能交换.

遍历簇中的每个点...
尝试把当前中心点换为簇中另一点.
计算替换后的总距离代价
选择让总距离最小的点作为中心点.

Δ 计算:

对非 medoid i , 设当前最近 medoid 为 m .

如新 medoid 为 o 则 m 更新为 o .

否则仍用 m .

$\Delta = \text{新距离} - \text{旧距离}$

四. 层次聚类.

- 4.1 凝聚: 每个点初始为一簇, 逐步合并
② 分裂: 所有点初始为一簇, 逐步分裂.

4.2. Ward法: $\Delta(C_i, C_j) = \frac{\|C_i\| \|C_j\|}{\|C_i\| + \|C_j\|} \| \mu_i - \mu_j \|^2$ 最小化方差增加.

4.3 流程: ① 初始化, N 个数据点, 每点单独为一个簇 (此时有 N 个簇)

重复: ② 计算距离, 计算任意两个簇之间的距离

③ 合并: 找到距离最近两个簇合并

直至手动停在想要的簇数 k .

④ 画 Dendrogram 谱系图.

Linkage 原则.

单连接: 簇距离 = 两簇之间最近两点的距离.

易“链式聚类”

全连接: 簇距离 = 两簇中最远点距离.

更稳健, 对异常值敏感

☆ 平均距离: 簇距离 = 两簇间所有点对的平均距离. 最常用

重心法: 簇距离 = 两簇中心之间的距离.

五. DBSCAN 密度聚类.

5.1. ϵ 邻域半径.

MinPts: 核心点的最小邻域点数.

定义: 核心点: 邻域内至少包括 MinPts 个点.

边界点: 在核心点邻域内, 但自身非核心


噪声点: 即非核心也非边界

密度直达: p 到 q 密度直达

$\Leftrightarrow p$ 为核心点, 且 $q \in N_\epsilon(p)$.

密度可达: 存在链 $p_1, \dots, p_n$, p_1 到 p_{n-1} 密度直达

密度相连: 存在 o 使 p 和 q 都密度可达于 o .



算法流程: ①标记所有点为非访问.

②对所有未访问 p :

a. 标记 p 为已访问

b. 找 p 的 ϵ -邻域 $N_\epsilon(p)$

c. 若 $|N_\epsilon(p)| < Minpts$: 标记 p 为噪声.

d. 否则:

新建簇 C 加入 p

对 $N_\epsilon(p)$ 中每个点 q :

若 q 未访问: 标记已访问, 扩展其邻域

若 q 不属于任何簇, 加入 C

3. 输出所有簇.

病毒式传播,
“感染”簇中每一个密度可达
的点.

访问过的 q : 有簇/噪声
→ 不动.
没访问过的 q : 顺着继续向外搜.

优点: 无需指定 k , 可发现任意形状簇, 抗噪声.

缺点: 对参数敏感, 高维中距离度量失效, 变密度效果差.

六. EM算法与高斯混合模型.

6-1. 高斯混合模型:

$$p(x) = \sum_{k=1}^K \pi_k N(x | \mu_k, \Sigma_k)$$

其中 π_k : 混合系数, $\sum_k \pi_k = 1$. N : 高斯分布.

隐变量: $z = [z_1, \dots, z_K]^T$, $z_k \in \{0, 1\}$, $\sum_k z_k = 1$

完全数据似然: $p(X, Z | \theta) = \prod_{i=1}^n \prod_{k=1}^K [\pi_k N(x_i | \mu_k, \Sigma_k)]^{z_{ik}}$

$$\ln p(X, Z | \theta) = \sum_{i=1}^n \sum_{k=1}^K z_{ik} [\ln \pi_k + \ln N(x_i | \mu_k, \Sigma_k)]$$

E步: 计算隐变量后验: $\gamma(z_{ik}) = E[z_{ik}] = \frac{\pi_k N(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i | \mu_j, \Sigma_j)}$

M步: 最大化Q函数: $Q(\theta, \theta^{old}) = E_z [\ln p(X, Z | \theta)]$

更新公式: $N_k = \sum_{i=1}^n \gamma(z_{ik})$

$$\mu_k^{new} = \frac{1}{N_k} \sum_{i=1}^n \gamma(z_{ik}) x_i$$

$$\Sigma_k^{new} = \frac{1}{N_k} \sum_{i=1}^n r(z_{ik}) (x_i - \mu_k^{new})(x_i - \mu_k^{new})^T$$

$$\hat{\eta}_k^{new} = \frac{N_k}{n}$$

例: $X = \{1, 2, 3\} \rightarrow 2$ 个簇.

已知参数: α_1, α_2 . (每个高斯占比).

$$\mathcal{N}_1: \mu_1, \sigma_1^2$$

$$\mathcal{N}_2: \mu_2, \sigma_2^2$$

隐变量: 每个点属于第一个高斯或是第二个高斯

E步: 设 $\alpha_1 = \alpha_2 = 0.5$, $\mu_1 = 1, \sigma_1^2 = 1$, $\mu_2 = 3, \sigma_2^2 = 1$

$$r_{ik} = \frac{\alpha_k N(x_i; \mu_k, \sigma_k^2)}{\sum_{j=1}^2 \alpha_j N(x_i; \mu_j, \sigma_j^2)} \quad (\text{贝叶斯}).$$

r_{ik} : 第 i 个元素属于第 k 个簇的概率.

$$N(1; 1, 1) = 1$$

$$N(1; 3, 1) = 0.1353$$

$$r_{11} = \frac{0.5 \times 1}{0.5 \times 1 + 0.5 \times 0.1353} \approx 0.88.$$

$$r_{21} = 0.5$$

$$r_{31} = 0.12$$

$$r_{12} = 0.12$$

$$r_{22} = 0.5$$

$$r_{32} = 0.88.$$

M步: $\alpha_k = \frac{1}{n} \sum_i r_{ik}$ $\alpha_1 = \frac{0.88 + 0.5 + 0.12}{3} = \frac{1.5}{3} = 0.5$ $\alpha_2 = 0.5$

$$\mu_k = \frac{\sum_i r_{ik} x_i}{\sum_i r_{ik}}$$

$$\mu_1 = 1.49 \quad \mu_2 = 2.51$$

$$\sigma_k^2 = \frac{\sum_i r_{ik} (x_i - \mu_k)^2}{\sum_i r_{ik}}$$

$$\sigma_1^2 \approx 0.6, \quad \sigma_2^2 \approx 0.6$$

6.2. EM算法的收敛.

每一轮都严格提升对数似然 $\log L(\theta^{\text{new}}) \geq \log L(\theta^{\text{old}})$

观测 X 隐 Z . (X, Z) .

$$L(\theta) = \log p(X|\theta)$$

E步构造的下界函数 Q :

$$Q(\theta, \theta_{\text{old}}) = E_{Z|X, \theta_{\text{old}}} [\log p(X, Z|\theta)]$$

$$\begin{aligned} \log p(X|\theta) &= \log \int p(X, Z|\theta) dZ = \log \int p(Z|X, \theta_{\text{old}}) \frac{p(X, Z|\theta)}{p(Z|X, \theta_{\text{old}})} dZ \\ &\geq \int p(Z|X, \theta_{\text{old}}) \log \frac{p(X, Z|\theta)}{p(Z|X, \theta_{\text{old}})} dZ. \end{aligned}$$

$$= \underbrace{E[\log p(X, Z|\theta)]}_{Q(\theta, \theta_{\text{old}})} - E[\log p(Z|X, \theta_{\text{old}})]$$

$$\text{当 } \theta = \theta_{\text{old}}, \quad Q(\theta_{\text{old}}, \theta_{\text{old}}) = L(\theta_{\text{old}})$$

$$\therefore \theta_{\text{new}} = \underset{\theta}{\operatorname{argmax}} Q(\theta, \theta_{\text{old}})$$

$$\therefore Q(\theta_{\text{new}}, \theta_{\text{old}}) \geq Q(\theta_{\text{old}}, \theta_{\text{old}})$$

$$L(\theta_{\text{new}}) \geq Q(\theta_{\text{new}}, \theta_{\text{old}}) \geq Q(\theta_{\text{old}}, \theta_{\text{old}}) = L(\theta_{\text{old}})$$

则 $L(\theta_{\text{new}}) \geq L(\theta_{\text{old}})$, 单调不减且有上界,

七. 谱聚类.

(特征向量)
7.1 把数据建图 $\rightarrow$ 求图的连通结构 $\rightarrow$ 将数据投影到低维

$\rightarrow$ K-means.

可以解决 K-means 无法解决的非凸、环形等不规则簇

7.2. 节点、边、社区.

7.3. ①建相似矩阵 W , 任意两点 i, j 计算相似度 (最常用高斯核)

越近 $\rightarrow W_{ij}$ 越大,

②构造, $L = D - W$ L : 拉普拉斯矩阵

D : 度矩阵 (对角阵, 每个元素为该点 W 之和).

③求 L 的前 k 小特征值对应的特征向量, 形成 k 维低维表示

④运行 k -means, 得到最终簇. 本例是图的连通模式.

$$W_{ij} = e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}} \quad \text{距离越小, 关系越近 } (i \neq j) \quad D_{ij} \text{ 越大}$$

$$W_{ii} = 0 \quad (i=j)$$

$$D_{ii} = \sum_j W_{ij} \quad \text{点 } i \text{ 与其他所有点总相似度, 可区分中心点 } (D_{ii} \text{ 大})$$

Laplace 矩阵 $L = D - W$ 直觉: 同一个簇内的点连接尽量强, 不同簇内的点连接尽量弱. 边缘点 (D_{ii} 小).

定义: 割边损失函数: $Cut(A, B) = \sum_{i \in A, j \in B} W_{ij}$

目标: $\min Cut(A, B)$

改进为 Ratio Cut 与 Normalized Cut 防止出现孤立点集

$\min Normal Cut \Leftrightarrow$ 求 L 最小特征值对应特征向量, 鼓励割大/中簇.

L : 对称半正定

vol : 簇内所有连接的总权重

总边权

连续空间中, $\Delta f = \nabla^2 f$ 表示函数变化的剧烈程度.


$$\text{在上: } (Lf)_i = \sum_j W_{ij} (f_i - f_j)$$

$$f^T L f = \frac{1}{2} \sum_{i,j} W_{ij} (f_i - f_j)^2, \text{ 所有相邻点对角"差值平方", 按相似度加权求和}$$

同一簇的点: $f_i \approx f_j \rightarrow (f_i - f_j)^2$ 很小, 整体 $f^T L f$ 很小.

不同簇之间, $(f_i - f_j)^2$ 很大, 整体很大

例:



$$0. W = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$1. L = D - W = \begin{bmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{bmatrix}$$

$$2. \boxed{\lambda_1 = 0, \lambda_2 = 0.38, \lambda_3 = 1.62, \lambda_4 = 3}$$

$$3. \mu_1 = [1, 1, 1, 1]^T \quad \mu_2 = [0.65, 0.25, -0.25, -0.65]^T$$

备注：此式仅表示
图结构

① ② ③ ④

$$4. K\text{-means} \rightarrow \{1, 2\} \quad \{3, 4\}$$

谱聚类的实值是4维。

算法	KNN	K-means	K-medoids	层次凝聚聚类
直觉	看最近N个点	反复更新簇中心	反复更新中心点	合并最近两类
核心	基于距离投票	最小化簇内SSE	用实际点，减少异常影响	距离+Linkage原则，树状图
适用	分类、回归、简单边界	球形、大小相近	同K-means	任意形状
优点	简单	快、简单	抗噪	不需先定K
缺点	慢、对K和距离敏感	需指定K，敏感	慢	慢、对噪声敏感，合并不逆

DBSCAN	EM-GMM
按密度找簇	按概率软归属
按邻域找核心/边界/噪声	EM算法
任意形状	椭球、倾斜簇
不指定K，抗噪，强于非凸	软隶属，可输出概率
对密度、超参敏感，高维难调	需K，敏感，高维失效

谱聚类
将数据看作图，后K-means
得L → 最小特征值 → 降维
最强非凸聚类
耗内存，需特征分解，指定K

