

一、降维.

1.1 维度灾难

高维空间中, 数据稀疏, 距离失效, 模型复杂度极大,

1.2 降维损失函数.

$\mathbb{R}^d \rightarrow \mathbb{R}^m$ ($m < d$) 且最小化信息损失.

原始数据: $X = [x_1, \dots, x_n]^T \in \mathbb{R}^{n \times d}$.

降维后: $Z = [z_1, \dots, z_n]^T \in \mathbb{R}^{n \times m}$

重构: $\tilde{X} = ZW^T$, 其中 $W \in \mathbb{R}^{d \times m}$.

误差: $J(W, Z) = \frac{1}{n} \sum_{i=1}^n \|x_i - Wz_i\|^2$.

$W^T W = I_m$ (正交性约束)

二、主成分分析.

2.1 最大方差视角.

越散开越有区分度 方差越大信息越多.

① 数据中心化: $\sum_{i=1}^n x_i = 0$.

② 一维投影: 方向 w_1 , $\|w_1\|=1$ $z_i = w_1^T x_i$ 找一条直线, 让投影的方差最大.

投影后方差: $\frac{1}{n} \sum_{i=1}^n z_i^2 = \frac{1}{n} \sum_{i=1}^n (w_1^T x_i)^2 = w_1^T \left(\frac{1}{n} \sum_{i=1}^n x_i x_i^T \right) w_1 = w_1^T S w_1$

$S = \frac{1}{n} X^T X$, 样本协方差矩阵.

数据变化大的方向, 包含更重要的结构; 变化小的方向是噪声.

定义: $\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$

若已中心化, $\bar{x} = 0, \bar{y} = 0$. $\text{Cov}(x, y) = \frac{1}{n} \sum_{i=1}^n x_i y_i$.

③ 优化: $\max_{w_1} w_1^T S w_1$
s.t. $w_1^T w_1 = 1$

④. $L(w_1, \lambda) = w_1^T S w_1 - \lambda (w_1^T w_1 - 1)$.

$\frac{\partial L}{\partial w_1} = 2S w_1 - 2\lambda w_1 = 0$.

$$S w_1 = \lambda w_1$$

故最优 w 为 S 最大特征值对应的特征向量 $\frac{w}{\|w\|}$.

→ 找一个方向, 让投影后误差最大, 而误差就是 λ

$$\star \text{误差} = w^T S w = \lambda w^T w = \lambda$$

2.2. 最小化重构误差视角.

目标: $\min_{W, Z} \|X - ZW^T\|_F^2$

s.t. $W^T W = I_m$.

定理: 最大误差 $\Leftrightarrow$ 最小重构误差.

$$\|X - ZW^T\|_F^2 = \text{tr}[(X - ZW^T)^T (X - ZW^T)]$$

$$= \text{tr}(X^T X) - 2\text{tr}(W^T X^T Z) + \text{tr}(Z^T Z)$$

固定 W , $\frac{\partial}{\partial Z} \|X - ZW^T\|_F^2 = -2(X - ZW^T)W = 0$

$$XW = ZW^T W = Z$$

故 $Z = XW$

代回得: $\min_W \|X - XWW^T\|_F^2 \text{ s.t. } W^T W = I$.

$$\therefore \|A\|_F^2 = \text{tr}(A^T A)$$

$$= \text{tr}[(X - XWW^T)^T (X - XWW^T)] = \text{tr}[X^T X] - 2\text{tr}[X^T XWW^T] +$$

$$\text{tr}[WW^T X^T X WW]$$

$$= \text{tr}(X^T X) - \text{tr}(W^T X^T X W)$$

$$\Leftrightarrow \max_W \text{tr}(W^T X^T X W) \text{ s.t. } W^T W = I$$

2.3. 特征值分解视角.

定理: $W = [w_1, \dots, w_m]$ 最优投影矩阵.

设 $S = U \Lambda U^T$

$$\max_{W^T W = I} \text{tr}(W^T S W) = \max_{W^T U = I} \sum_{j=1}^m u_j^T S u_j$$

由瑞利商定理: $\max_{\|w\|=1} w^T S w = \lambda_1$, 达到 w_1

$\max_{\|w\|=1, w \perp w_1} w^T S w = \lambda_2$, 达到 w_2

依此类推.

对任一组正交向量 $w_1, \dots, w_m$, 有 $\sum_{i=1}^m w_i^T S w_i \leq \lambda_1 + \dots + \lambda_m$
等式成立当且仅当 $\{w_1, \dots, w_m\} = \{v_1, \dots, v_m\}$.

三. PCA 算法.

3.1 标准 PCA.

输入: $X \in \mathbb{R}^{n \times d}$, 目标 m 维

输出: $Z \in \mathbb{R}^{n \times m}$, 投影矩阵 W .

① 数据中心化: $X_c = X - \bar{X}$

② $S = \frac{1}{n} X^T X$

③ $S = U \Lambda U^T$

④ 取前 m 个最大特征值对应特征向量: $W = [w_1, \dots, w_m]$

⑤ $Z = X_c W$

3.2 基于 SVD 的 PCA (数值稳定)

直接算 $X^T X$ 会丢失精度,
SVD 避免显式构造 $X^T X$.



$$X_c = U \Sigma V^T, \quad U \in \mathbb{R}^{n \times n}, \quad U^T U = I$$

$$\Sigma \in \mathbb{R}^{n \times d}, \quad \sigma_1 \geq \dots \geq \sigma_r \geq 0$$

$$V \in \mathbb{R}^{d \times d}, \quad V^T V = I$$

$$S = \frac{1}{n} X^T X = \frac{1}{n} V \Sigma^T \Sigma V^T \quad (U \text{ 正交}).$$

$$\lambda_i = \frac{1}{n} \sigma_i^2$$

特征向量 $w_i = v_i$

SVD PCA算法:

① 数据中心化

② 计算SVD: $X = U \Sigma V^T$

③ 取前m个右奇异向量: $W = V[:, 1:m]$

④ $Z = XW = U[:, 1:m] \Sigma[:, 1:m]$

SVM的奇异值分解:

按大小顺序排列

四. PCA的数学性质:

4.1. 第k主成分方差: $\text{Var}(z_k) = W_k^T S W_k = \lambda_k$

累计方差贡献率: $\frac{\sum_{j=1}^m \lambda_j}{\sum_{j=1}^n \lambda_j}$

因为特征值对应方差

4.1. $W_i^T W_j = 0, i \neq j$

$\text{Cov}(z_i, z_j) = W_i^T S W_j = \lambda_j W_i^T W_j = 0$

4.3. PCA是数据的最佳m维线性逼近

$$\|X - X W W^T\|_F^2 \geq \|X - X W^* W^{*T}\|_F^2$$

常用公式:

$$\frac{\partial}{\partial X} \text{tr}(X) = I$$

$$\frac{\partial}{\partial X} \text{tr}(AX) = A^T$$

$$\frac{\partial}{\partial X} \text{tr}(X/A) = A^T$$

$$\frac{\partial}{\partial X} \text{tr}(AXB) = A^T B^T$$

$$\frac{\partial}{\partial X} \text{tr}(X^T A) = A$$

$$\frac{\partial}{\partial X} \text{tr}(AX^T B) = BA$$

$$\frac{\partial}{\partial X} \text{tr}(X^T A X) = (A + A^T)X$$

$$\frac{\partial}{\partial X} \text{tr}(X A X^T B) = B X A + B^T X A^T$$

$$\frac{\partial}{\partial X} \|X\|_F^2 = \frac{\partial}{\partial X} \text{tr}(X^T X) = 2X$$

$$\frac{\partial}{\partial X} \|A - XB\|_F^2 = -2(A - XB)B^T$$

五. 核 PCA / Kernel PCA

有内核的地方就可以用核技巧

$\varphi: \mathbb{R}^d \rightarrow H$

假设数据已中心化, $\sum_i \varphi(x_i) = 0$

$$C = \frac{1}{n} \sum_{i=1}^n \varphi(x_i) \varphi(x_i)^T$$

$$Cv = \lambda v$$

$$v = \sum_{i=1}^n \alpha_i \varphi(x_i)$$

代入得: $\frac{1}{n} \sum_{i=1}^n \varphi(x_i) \varphi(x_i)^T \sum_{j=1}^n \alpha_j \varphi(x_j) = \lambda \sum_{j=1}^n \alpha_j \varphi(x_j)$

极化: $\frac{1}{n} \sum_{i=1}^n k(x_k, x_i) \sum_{j=1}^n \alpha_j k(x_i, x_j) = \lambda \sum_{i=1}^n \alpha_i k(x_k, x_i)$ ($\frac{\partial}{\partial B} \|A - XB\|_F^2 = -2X^T(A - XB)$)

矩阵化: $\frac{1}{n} K K \alpha = \lambda K \alpha$.

$K \alpha = \underline{n \lambda} \alpha$.

实际我们不用对 $\psi(x_i)$ 显式计算, 也就不中心化

$\tilde{K} = K - \mathbf{1}_n \mathbf{1}_n^T K - K \mathbf{1}_n \mathbf{1}_n^T + \mathbf{1}_n \mathbf{1}_n^T K \mathbf{1}_n$.

其中 $(\mathbf{1}_n)_{ij} = \frac{1}{n}$